

## 9 Estimación puntual II

### 9.1 Estimadores consistentes e insesgados

Según el teorema de Glivenko-Cantelli, sabemos que la muestra tiende a dar información completa sobre la distribución teórica cuando crece su tamaño.

**Definición.** Una sucesión de estimadores  $T_1, T_2, \dots$  asociada a los sucesivos tamaños muestrales  $n$ , se denomina consistente para estimar una función  $g(\theta)$  si  $T_n \xrightarrow{p} g(\theta)$  para  $\theta \in \Theta$ .

**Ejemplo.** La media muestral  $\bar{X}_n$  es un estimador consistente de la media poblacional  $\mu = g(\theta)$ , ya que, por la ley débil de los grandes números, se tiene que  $\bar{X}_n \xrightarrow{p} \mu$  para todo  $\theta \in \Theta$ . Esta consistencia es válida para cualquier distribución con  $\mu$  finita.

Si  $\lim_{n \rightarrow \infty} \mathbb{E}_\theta[T_n] = g(\theta)$  y  $\lim_{n \rightarrow \infty} \text{var}_\theta[T_n] = 0$  para todo  $\theta \in \Theta$ , entonces  $T_n$  es consistente para  $g(\theta)$ . En particular, como  $\mathbb{E}[\bar{X}_n] = \mu$  y  $\text{var}[\bar{X}_n] = \sigma^2/n$ , se cumple la condición anterior y se concluye que  $\bar{X}_n$  es consistente para  $\mu$ .

**Ejemplo.** Sea  $X_1, \dots, X_n \sim \text{Exp}(\theta)$  una m.a.s. que modela la duración de  $n$  LEDs con tasa de fallo constante. El MLE de  $\mu = \frac{1}{\theta}$  es  $\bar{X}$ , que es un estimador consistente. Se propone un estimador alternativo  $T = nX_{(1)}$ , que solo requiere esperar al primer fallo. Se tiene:  $P(T \leq t) = 1 - e^{-\theta t} \Rightarrow T \sim \text{Exp}(\theta)$ , por lo que  $E[T] = \frac{1}{\theta} = \mu$  y  $\text{var}[T] = \frac{1}{\theta^2}$ . Aunque  $\mathbb{E}[T] = \mu$ ,  $T$  no es consistente, ya que su distribución no depende de  $n$  y no se concentra alrededor de  $\mu$  al crecer  $n$ .

**Comentario.** Los momentos y cuantiles muestrales se aproximan a los poblacionales al crecer el tamaño muestral, es decir, son estimadores consistentes.

**Definición.** El sesgo de  $T$  para estimar  $g(\theta)$  es

$$b_T(g(\theta)) = \mathbb{E}_\theta[T] - g(\theta)$$

Un estimador es *insesgado* si  $\mathbb{E}_\theta[T] = g(\theta)$ .

**Ejemplo.** La media muestral  $\bar{X}$  y la cuasivarianza  $S^2$  son estimadores insesgados de  $\mu$  y  $\sigma^2$ . La varianza muestral  $s^2$  tiene sesgo:  $b_{s^2}(\sigma^2) = \mathbb{E}[s^2] - \sigma^2 = \frac{n-1}{n}\sigma^2 - \sigma^2 = -\frac{\sigma^2}{n}$ , que desaparece cuando  $n \rightarrow \infty$ , así que es asintóticamente insesgada.

**Comentario.** Si  $\hat{\theta}$  es insesgado para  $\theta$ , entonces  $g(\hat{\theta})$  es insesgado para  $g(\theta)$  solo si  $g$  es lineal. Por ejemplo, aunque  $S^2$  es insesgado para  $\sigma^2$ ,  $S$  no lo es para  $\sigma$  en general.

## 9.2 Error cuadrático medio como medida de la bondad de un estimador

El sesgo no siempre refleja bien la calidad de un estimador: un estimador puede ser insesgado y muy malo (como usar solo un dato), mientras que otro con ligero sesgo puede ser mucho más fiable al aprovechar mejor la información.

Sea  $T$  un estimador de  $\theta$  y  $t$  un valor observado. La discrepancia entre  $\theta$  y  $t$  se mide mediante una función de pérdida  $L(\theta, t)$ , que puede reflejar distintos tipos de errores o costes asociados, como el error relativo o el cuadrático.

**Definición** (Función de riesgo). El riesgo del estimador  $T$  es la pérdida esperada

$$R_T(\theta) = \mathbb{E}_\theta[L(\theta, T)],$$

función que depende de  $\theta$ .

**Definición** (Error cuadrático medio). El *error cuadrático medio* de un estimador  $\hat{\theta}$  es

$$\mathbb{E}_\theta[(\hat{\theta} - \theta)^2]$$

Podemos expresar el error cuadrático medio en términos de la varianza y el sesgo:

$$\begin{aligned} \mathbb{E}_\theta[(\hat{\theta} - \theta)^2] &= \mathbb{E}_\theta[(\hat{\theta} - \mathbb{E}_\theta(\hat{\theta}) + \mathbb{E}_\theta(\hat{\theta}) - \theta)^2] \\ &= \mathbb{E}_\theta[(\hat{\theta} - \mathbb{E}_\theta(\hat{\theta}))^2] + [\mathbb{E}_\theta(\hat{\theta}) - \theta]^2 + 2\mathbb{E}_\theta[\mathbb{E}_\theta(\hat{\theta}) - \theta] \underbrace{\mathbb{E}_\theta[\hat{\theta} - \mathbb{E}_\theta(\hat{\theta})]}_0 \\ &= \text{var}(\hat{\theta}) + \text{bias}^2(\hat{\theta}) \end{aligned}$$

Si nuestro objetivo es minimizar el error cuadrático medio, en ocasiones puede ser preferible utilizar un estimador sesgado con menor varianza.

**Ejemplo.** Sea  $X \sim \mathcal{B}(n, \theta)$  con  $n$  conocido. El estimador usual es  $T_U = \frac{X}{n}$ , insesgado, con varianza

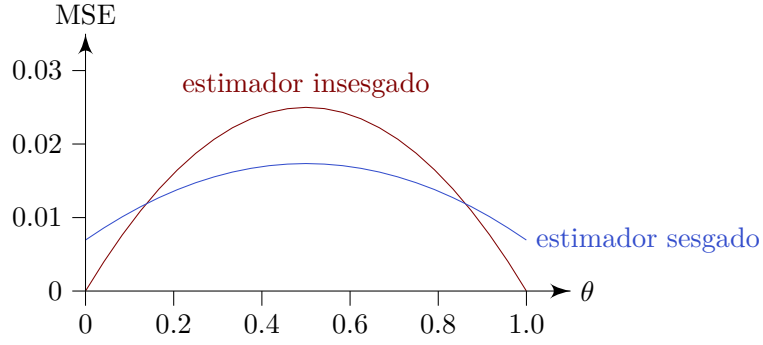
$$\text{var}_\theta(T_U) = \frac{\text{var}_\theta(X)}{n^2} = \frac{\theta(1-\theta)}{n}$$

Su error cuadrático medio es  $\text{mse}(T_U) = \frac{\theta(1-\theta)}{n}$ . Consideremos el estimador alternativo  $T_B = \frac{X+1}{n+2} = w\frac{X}{n} + (1-w)\frac{1}{2}$ , con  $w = \frac{n}{n+2}$ . Su sesgo y varianza son

$$b(T_B) = \mathbb{E}_\theta[T_B] - \theta = (1-w)\left(\frac{1}{2} - \theta\right), \quad \text{var}_\theta(T_B) = \frac{\text{var}_\theta(X)}{(n+2)^2} = w^2 \frac{\theta(1-\theta)}{n}$$

Por tanto, su MSE es  $\text{mse}(T_B) = w^2 \frac{\theta(1-\theta)}{n} + (1-w)^2 \left(\frac{1}{2} - \theta\right)^2$ .

Podemos representar gráficamente el error cuadrático medio de cada estimador para distintos valores posibles de  $\theta$ . A continuación, se muestra el caso en el que  $n = 10$ :



Este estimador sesgado tiene un menor error cuadrático medio, salvo cuando  $\theta$  toma valores extremos.

**Definición.** Se dice que un estimador  $T_1$  es preferible a otro  $T_2$  para estimar  $g(\theta)$  si  $R_{T_1}(\theta) \leq R_{T_2}(\theta)$  para todo  $\theta \in \Theta$  y  $R_{T_1}(\theta) < R_{T_2}(\theta)$  para algún  $R_{T_1}(\theta) < R_{T_2}(\theta)$ .

Aunque sería ideal hallar un estimador preferible a todos, a menudo no existe.

**Ejemplo.** Sea una m.a.s. de tamaño  $n$  de una distribución  $\mathcal{N}(\mu, \sigma)$ . Se comparan  $\bar{X}$  y la mediana muestral  $M$  como estimadores de  $\mu$ . Se tiene:  $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$ ,  $M \sim \mathcal{AN}\left(\mu, \frac{\sigma\sqrt{\pi}}{\sqrt{2n}}\right)$ . Ambos son (asintóticamente) insesgados, pero el cociente de errores cuadráticos medios es

$$\frac{\text{MSE}(\bar{X})}{\text{MSE}(M)} \approx \sqrt{\frac{2}{\pi}} \approx 0,8$$

Por tanto, para  $n$  grande,  $\bar{X}$  es preferible. Sin embargo,  $M$  es más robusto ante datos atípicos.

**Ejemplo.** Consideramos una muestra aleatoria  $X_1, X_2, \dots, X_n \sim U(0, \theta)$  con  $\theta > 0$  desconocido. Para construir un estimador insesgado de  $\theta$ , usamos  $X_{(n)} = \max\{X_1, \dots, X_n\}$ . Primero, obtenemos su función de densidad:

$$F_{X_{(n)}}(z) = P(X_{(n)} \leq z) = P(X_1 \leq z, \dots, X_n \leq z) = [F_X(z)]^n = \left(\frac{z}{\theta}\right)^n$$

para  $0 < z < \theta$ . Derivando, obtenemos la función de densidad:

$$f_{X_{(n)}}(z) = \frac{d}{dz} \left(\frac{z}{\theta}\right)^n = \frac{nz^{n-1}}{\theta^n}, \quad 0 < z < \theta$$

Ahora, calculamos la esperanza del máximo

$$\mathbb{E}[X_{(n)}] = \int_0^\theta z \cdot \frac{nz^{n-1}}{\theta^n} dz = \frac{n}{\theta^n} \int_0^\theta z^n dz = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1} \theta$$

Buscamos una constante  $c$  tal que  $T = cX_{(n)}$  sea insesgado, es decir,  $\mathbb{E}[T] = \theta$ . Como  $\mathbb{E}[X_{(n)}] = \frac{n}{n+1} \theta$ , se deduce que  $c = \frac{n+1}{n}$ , y así  $T = \frac{n+1}{n} X_{(n)}$  es un estimador insesgado de  $\theta$ .

Finalmente, este estimador es consistente, ya que  $X_{(n)} \xrightarrow{p} \theta$  al crecer  $n$ , y el factor  $\frac{n+1}{n} \rightarrow 1$ , por lo tanto  $T \xrightarrow{p} \theta$ .

**Ejemplo.** Buscamos  $c_0$  tal que  $T = c_0 X_{(n)}$  minimice el MSE dentro de los estimadores  $cX_{(n)}$ . Tenemos que  $\mathbb{E}[X_{(n)}] = \frac{n}{n+1}\theta$  y  $\mathbb{E}[X_{(n)}^2] = \frac{n}{n+2}\theta^2$ . Entonces, para  $T = cX_{(n)}$ :

$$\text{sesgo} = \left(c \frac{n}{n+1} - 1\right)\theta, \quad \text{var}(T) = c^2 \left(\frac{n}{n+2} - \left(\frac{n}{n+1}\right)^2\right)\theta^2$$

$$\text{MSE}(T) = \left(\frac{n}{n+2}c^2 - 2\frac{n}{n+1}c + 1\right)\theta^2 = h(c)\theta^2$$

El mínimo de  $h(c)$  se alcanza en  $c_0 = \frac{n+2}{n+1}$ . Por tanto, el mejor estimador de la forma  $cX_{(n)}$  (en términos de MSE) es:  $T = \frac{n+2}{n+1}X_{(n)}$ .

**Ejemplo.** Sea  $X_1, \dots, X_n \sim U(0, \theta)$ , con  $\theta > 0$ , y sea  $\mu = \frac{\theta}{2}$ . Se comparan dos estimadores de  $\mu$ :  $T_1 = \frac{c}{2}X_{(n)}$  con  $c = \frac{n+2}{n+1}$ , y  $T_2 = \bar{X}$ .  $\text{MSE}(T_1) = \frac{1}{4}\text{MSE}(cX_{(n)}) = \frac{1}{4}h(c)\theta^2$  con  $h(c) = \frac{n}{n+2}c^2 - 2\frac{n}{n+1}c + 1$ . Para  $c = \frac{n+2}{n+1}$ , se obtiene

$$\text{MSE}(T_1) = \frac{-(n(n+2) - (n+1)^2)}{4(n+1)^2}\theta^2 = \frac{1}{4(n+1)^2}\theta^2$$

Para  $T_2$ ,

$$\text{MSE}(\bar{X}) = \text{var}(\bar{X}) = \frac{\theta^2}{12n}$$

Por tanto,  $\frac{1}{4(n+1)^2} < \frac{1}{12n} \quad \forall n \Rightarrow \text{MSE}(T_1) < \text{MSE}(T_2)$ .  $T_1 = \frac{n+2}{2(n+1)}X_{(n)}$  es preferible a  $\bar{X}$  para estimar  $\mu = \frac{\theta}{2}$ . Además, su MSE converge a 0 más rápido que el de  $\bar{X}$ .

### 9.3 Estimador centrado de uniformemente mínima varianza

**Definición** (Estimador centrado de uniformemente mínima varianza). Un estimador centrado  $T$  de  $g(\theta)$  con varianza finita es ECUMV si para todo estimador centrado  $T'$  con varianza finita se cumple  $\text{var}_\theta(T) \leq \text{var}_\theta(T')$  para todo  $\theta \in \Theta$ .

**Comentario.** Si existe, el ECUMV es único y preferible pues su MSE coincide con la varianza.

**Teorema** (de Rao-Blackwell). Si  $S$  es suficiente para  $\{F_\theta\}$  y  $T_1$  es estimador insesgado centrado de  $g(\theta)$ , entonces  $T_2 = \mathbb{E}[T_1 | S]$  cumple:

- (a)  $T_2$  es independiente de  $\theta$ .
- (b)  $T_2$  es insesgado para  $g(\theta)$ .
- (c)  $\text{var}_\theta(T_2) \leq \text{var}_\theta(T_1)$ , con igualdad solo si  $T_2 = T_1$  casi seguro.

*Demostración.* (a) Como la distribución de la muestra condicionada a  $S$  no depende de  $\theta$ , tampoco  $\mathbb{E}_\theta[T_1 | S]$ , luego  $T_2$  es un estimador independiente de  $\theta$ .

(b) Se tiene  $\mathbb{E}_\theta[T_2] = \mathbb{E}_\theta[\mathbb{E}[T_1 | S]] = \mathbb{E}_\theta[T_1] = g(\theta)$ , por lo que  $T_2$  es insesgado.

(c) Por la descomposición de varianza,  $\text{var}_\theta[T_1] = \text{var}_\theta(\mathbb{E}[T_1 | S]) + \mathbb{E}_\theta[\text{var}(T_1 | S)] \geq \text{var}_\theta[T_2]$ , con igualdad si y sólo si  $\text{var}(T_1 | S) = 0$  casi seguro, es decir,  $T_1 = T_2$  casi seguro.

□

Anteriormente se han considerado sólo estimadores insesgados, donde el ECM coincide con la varianza. Rao-Blackwell mejora un estimador insesgado  $T_1$  obteniendo  $T_2 = \mathbb{E}[T_1 | S]$ , función del estadístico suficiente  $S$ , con varianza menor o igual a la de  $T_1$ . Así, el ECUMV, si existe, debe ser función de  $S$ . Si  $T_1$  no es función de  $S$ , entonces  $T_2 \neq T_1$  es preferible, por lo que  $T_1$  no es ECUMV. Además,  $T_2$  es función de  $S$  y satisface  $\mathbb{E}[T_2 | S] = \mathbb{E}[T_2 \cdot 1 | S] = T_2 \cdot \mathbb{E}[1 | S] = T_2$ .

Frecuentemente, existe una única función  $h$  del estadístico suficiente minimal  $S$  que es insesgada para  $g(\theta)$ . En este caso, por Rao-Blackwell,  $h(S)$  debe ser el ECUMV, y además:  $h(S) = \mathbb{E}[T_1 | S]$  para cualquier estimador insesgado  $T_1$ .

**Teorema** (Lehmann-Scheffé). Si  $S$  es un estadístico suficiente y completo, y existe  $T$  de  $\theta$  insesgado, entonces existe un único ECUMV para  $\theta$ , y viene dado por  $\mathbb{E}[T | S]$ .

En todos los ejemplos, el estadístico suficiente  $s_m$  es completo, por lo que el ECUMV es la única función centrada de  $s_m$ . A veces se obtiene directamente, otras calculando  $\mathbb{E}[T | S]$ .

**Ejemplo.** Para las siguientes familias y funciones  $g$ , el ECUMV es la única función centrada del estadístico suficiente  $s_m$ :

- (a)  $\mathcal{B}(1, \theta)$ ,  $g(\theta) = \theta$ :  $SM = \bar{X}$  es suficiente e insesgado para  $\mu = \theta$ , luego ECUMV.
- (b)  $\mathcal{P}(\theta)$ ,  $g(\theta) = \theta$ :  $SM = \bar{X}$  es suficiente e insesgado para  $\mu = \theta$ , luego ECUMV.
- (c)  $\mathcal{N}(\mu, \sigma)$ ,  $g(\mu, \sigma) = \mu$ :  $SM = (\bar{X}, S^2)$ , y  $\bar{X}$  es insesgado para  $\mu$  y función de  $SM$ , luego ECUMV.
- (d)  $\mathcal{N}(\mu, \sigma)$ ,  $g(\mu, \sigma) = \sigma^2$ :  $SM = (\bar{X}, S^2)$ , y  $S^2$  es insesgado para  $\sigma^2$  y función de  $SM$ , luego ECUMV.

**Ejemplo.** Sea  $X_1, \dots, X_n$  una m.a.s. de  $\mathcal{B}(1, \theta)$ . Queremos estimar  $g(\theta) = \theta(1 - \theta) = \sigma^2$ . Como  $SM = \sum X_i$  es suficiente y completo, el ECUMV es la única función centrada de  $SM$ . Se tiene que  $SM = \bar{X}$ . No parece sencillo encontrar de modo directo una función centrada del estadístico suficiente  $\bar{X}$ .

Sea  $T_1 = \mathbb{I}_{\{X_1=1, X_2=0\}}$ , que es centrado para  $g(\theta)$ , puesto que  $\mathbb{E}_\theta[T_1] = 1 \cdot \mathbb{P}(T_1 = 1) + 0 \cdot \mathbb{P}(T_1 = 0) = \mathbb{P}(X_1 = 1, X_2 = 0) = \mathbb{P}(X_1 = 1) \cdot \mathbb{P}(X_2 = 0) = \theta(1 - \theta) = g(\theta)$ . Es

ahora más cómodo considerar el estadístico suficiente  $SM = \sum_{i=1}^n X_i$ , que tiene distribución  $\mathcal{B}(n, \theta)$ . Queremos calcular  $\mathbb{E}[T_1 \mid SM = s] = \mathbb{P}(T_1 = 1 \mid SM = s)$  y

$$\begin{aligned} \mathbb{P}(T_1 = 1 \mid SM = s) &= \mathbb{P}(X_1 = 1, X_2 = 0 \mid \sum_{i=1}^n X_i = s) \\ &= \frac{\mathbb{P}(X_1 = 1, X_2 = 0, \sum_{i=3}^n X_i = s-1)}{\mathbb{P}(\sum_{i=1}^n X_i = s)} \\ &= \frac{\theta \cdot (1-\theta) \cdot \mathbb{P}(\mathcal{B}(n-2, \theta) = s-1)}{\mathbb{P}(\mathcal{B}(n, \theta) = s)} \\ &= \frac{\theta(1-\theta) \binom{n-2}{s-1} \theta^{s-1} (1-\theta)^{n-s-1}}{\binom{n}{s} \theta^s (1-\theta)^{n-s}} \\ &= \frac{\binom{n-2}{s-1}}{\binom{n}{s}}. \end{aligned}$$

Utilizando la identidad combinatoria:  $\frac{\binom{n-2}{s-1}}{\binom{n}{s}} = \frac{s(n-s)}{n(n-1)}$ , concluimos que el ECUMV para  $g(\theta) = \theta(1-\theta) = \sigma^2$  es:  $\mathbb{E}[T_1 \mid SM] = \frac{SM(n-SM)}{n(n-1)} = \frac{\bar{X}(1-\bar{X})}{n-1}$ .

**Ejemplo.** Sea  $X_1, \dots, X_n$  una m.a.s. de  $P(\theta)$ . Queremos estimar  $g(\theta) = P_\theta(X > 0) = 1 - e^{-\theta}$ . El ECUMV es único y es la única función centrada del estadístico suficiente  $SM = \sum_{i=1}^n X_i$ . Sea  $T_1 = \mathbb{I}_{\{X_1 > 0\}}$ , entonces:  $\mathbb{E}[T_1] = P(X_1 > 0) = 1 - e^{-\theta} = g(\theta)$ . Por tanto, aplicando el teorema,

$$\begin{aligned} \mathbb{E}[T_1 \mid S_M = s] &= P(X_1 > 0 \mid S_M = s) = 1 - P(X_1 = 0 \mid S_M = s) \\ &= 1 - \frac{P(X_1 = 0) \cdot P(\sum_{i=2}^n X_i = s)}{P(S_M = s)} \\ &= 1 - \frac{e^{-\theta} \cdot \frac{[(n-1)\theta]^s}{s!} e^{-(n-1)\theta}}{\frac{(n\theta)^s}{s!} e^{-n\theta}} = 1 - \left(\frac{n-1}{n}\right)^s \end{aligned}$$

Luego, el ECUMV es  $\mathbb{E}[T_1 \mid S_M] = 1 - \left(\frac{n-1}{n}\right)^{S_M} = 1 - \left(1 - \frac{1}{n}\right)^X$ . El EMV de  $g(\theta)$  es  $1 - e^{-\hat{\theta}} = 1 - e^{-X}$ . y ambos son próximos para  $n$  grande, ya que  $\left(1 - \frac{1}{n}\right)^n \rightarrow e^{-1}$ . Además, si  $T_1, T_2$  son ECUMV para  $g_1(\theta)$  y  $g_2(\theta)$ , entonces  $T = aT_1 + bT_2$  es ECUMV para  $ag_1(\theta) + bg_2(\theta)$ .

**Ejemplo.** Consideremos una m.a.s. de una distribución teórica  $B(1, \theta)$ . Obtenemos el ECUMV para  $g(\theta) = \theta^2$ . Se tiene que  $g(\theta) = g_1(\theta) - g_2(\theta)$ , con  $g_1(\theta) = \theta$  y  $g_2(\theta) = \theta(1-\theta)$ . En ejemplos anteriores obtuvimos el ECUMV para  $g_1(\theta)$ , que es  $T_1 = \bar{X}$ , y el ECUMV para  $g_2(\theta)$ , que es  $T_2 = \frac{n}{n-1} \bar{X}(1-\bar{X})$ . Entonces, el ECUMV para  $g(\theta) = g_1(\theta) - g_2(\theta) = \theta^2$  es  $T = T_1 - T_2 = \bar{X} - \frac{n}{n-1} \bar{X}(1-\bar{X}) = \frac{n}{n-1} \bar{X}^2 - \bar{X}$ .